

ANALYSIS FOR SPATIO TEMPORAL DEPENDENCE STRUCTURE OF PM2.5

USING SAR AND CAR

김준식

thejs@snu.ac.kr

최근 미세먼지의 심각성에 대한 많은 논의가 이루어지고 있지만 지역적 요소에 따른 미세먼지의 영향을 수치적으로 측정하기란 쉽지않으며 따라서 바람, 주요 발생국으로부터의 거리, 이웃한 국가의 수 등 다양한 외부적 요인을 함께 고려하여 연구하기란 현실적으로 매우 어려운 작업이다. 본 보고서에서는 이러한 지역적 연관성을 고려하여 **각 국가의 초미세먼지가 어떠한 요인에 영향을 받는지 확인**해 본다. 공간 구조 특히 본 연구에서 사용하는 국가별 초미세먼지 농도와 같은 비정규적 격자 형태의 구조가 있는 데이터를 분석하기 위해서는 우선 공간 구조에 대한 정보를 반영하는 조건부 분포에 기반한 Gaussian Markov Random Fields(GMRF)를 이용할 수 있다. 본 보고서에서는 GMRF 기반의 Simultaneous Autoregressive model(SAR), Conditional Autoregressive model(CAR) 등 공간적 의존성을 고려할뿐 아니라 ~~공간적요소를 반영하는 AR(1) 모형~~ 타입의 CAR 모형을 통해 초미세먼지의 평균 농도를 분석하고 화석연료 사용량, 연간 평균 강수량 및 국토에서 숲이 차지하는 비율 등 여러 변수들의 영향을 고려하도록 한다.



Keywords : 초미세먼지(PM2.5), Gaussian Markov Random Fields, SAR, CAR, CAR+AR(1)

1 INTRODUCTION

최근 미세먼지의 심각성에 대한 많은 논의가 이루어지고 있다. 실제로 2017년 5월 말 기준으로 미세먼지 농도가 $30\mu\text{g}/\text{m}^3$ 이하인 환경부 기준으로 "좋음" 단계는 단 6일에 그쳤다. 미세먼지 "보통" 단계인 $31 \sim 80\mu\text{g}/\text{m}^3$, "나쁨" 단계인 $81 \sim 150\mu\text{g}/\text{m}^3$ 또한 $151\mu\text{g}/\text{m}^3$ 를 초과하는 "매우 나쁨" 단계는 각각 132일, 11일, 2일이었다. 하지만 세계보건기구(WHO)에서 제안하는 미세먼지 농도의 기준을 적용하면 "보통" 단계는 $25\mu\text{g}/\text{m}^3$ 이하인 경우로 이를 우리 나라에 적용할 경우 2017년 동안 "나쁨" 수준 이상의 경우는 151일 중 최소 145일로 나타난다. [조재근 기자. 충청일보,

2017. 06. 09]

미세먼지는 세계보건기구 산하 국제암연구소(IARC)에서 정한 1급 발암물질이며 폐암의 원인으로 지목되며 신경세포를 손상시켜 치매, 부정맥 등의 원인이 될 수 있다. 하지만 미세먼지의 원인에 대한 실제적 연구는 이루어지지 않고 있다. 또한 미세먼지의 정의 역시 명확하지 않으며 단지 미세먼지를 구성하는 입자의 크기에 따라 $10\mu m$ 이하의 경우는 미세먼지, $2.5\mu m$ 이하의 경우는 초미세먼지로 정의할 뿐 구성입자에 대한 구체적인 구분은 이루어지지 않고 있다. 따라서 크기에 따라 구분되는 미세먼지의 원인을 명확하게 밝혀내기는 쉽지 않다. 다만 그 주원인으로 화석연료, 사막의 모래, 자동차 및 공장의 대기가스 등이 지목되고 있다. 하지만 이러한 입자의 발생원인 못지 않게 지역적 요소를 고려하지 않을 수 없는데, 실제로 중국에서 발생하는 스모그를 한국에서 발생하는 미세먼지의 주요인으로 지목하는 경우도 많다. 이러한 지역적 요소에 따른 미세먼지의 영향을 수치적으로 측정하기란 쉽지 않으며 따라서 바람, 주요 발생국으로부터의 거리, 이웃한 국가의 수 등 다양한 외부적 요인을 함께 고려하여 연구하기란 현실적으로 매우 어려운 작업이다.

본 보고서에서는 이러한 지역적 연관성을 고려하여 각 국가의 초미세먼지가 어떠한 요인에 영향을 받는지 확인해 본다. 먼저, 제 2장에서는 본 보고서에서 사용되는 데이터에 대한 소개와 전처리 과정에 대해 간략히 설명하고 제 3장에서 분석에 사용되는 시공간적 통계 모형을 소개한다. 제 4장에서는 분석 결과를 바탕으로 미세먼지에 영향을 주는 요인을 찾도록 한다. 그리고 제 5장 결론을 끝으로 보고서를 마치도록 한다.

2 DATA AND PREPROCESSING

우선 분석에 사용될 초미세먼지 데이터는 World Bank(<http://data.worldbank.org/>)에서 제공하는 국가별 초미세먼지(PM2.5) 자료 중 총 217개 국가의 2010년부터 2014년까지 초미세먼지 연간 평균 농도를 사용하였다. Table 1.은 주요 국가들의 2010년부터 2014년까지의 초미세먼지의 연간 평균 농도이다.

Table 1.에서 초미세먼지 주요 발생국 중 하나인 중국과 국경을 공유하는 북한의 경우 마찬가지로 높은 초미세먼지 농도를 나타내고 있음을 알 수 있으며, 중국과 지리적으로 이웃하지는 않았지만 중국과의 물리적 거리가 가깝다는 것을 고려했을 때 한국 역시 초미세먼지의 농도가 상대적으로 높게 나타나는 것이 단지 내부적 요인에 의한 것만은 아님을 추측해 볼 수 있다. 그에 반해 한국, 북한 그리고 동해, 동중국해를 통해 중국과 분리되어 있는 일본의 경우 초미세먼지의 농도가 크게 높지 않음을

알 수 있다. 미국과 캐나다의 경우 서로 인접해 있다는 점에서 두 국가의 초미세먼지 역시 비슷한 정도로 낮게 나타난 점이 지리적 조건이 영향을 준 것이라 생각해 볼 수 있다. Figure 1.과 Figure 2.는 각각 국가별 2010년과 2014년 초미세먼지 평균 농도를 나타낸다. 그림에서 보듯이 최대 공업국인 중국과 인도, 사막이 많은 중동 지역과 아프리카 지역의 국가들이 초미세먼지 농도가 높은 반면, 북아메리카와 유럽 지역의 초미세먼지 농도가 대체로 낮음을 확인할 수 있다. 또한 시간에 따라 지역별로 약간씩 차이를 보임을 알 수 있다. Figure 1.과 Figure 2.에서 배경과 같은 색을 띠는 국가의 경우는 초미세먼지 농도가 World Bank에 보고되지 않은 결측치이다.

이와 같이 국가별 초미세먼지 농도의 차이는 주변국들의 농도에 영향을 받고 있음을 추측해 볼 수 있다. 따라서 본 보고서에서는 이와 같은 주변국 정보를 반영하여 시공간 모형을 설정하기 위해 주변국 정보를 바탕으로 국가간 인접행렬(Adjacent Matrix)을 만들기로 한다. 국가간 지리적 인접 정보에 대한 자료는 wikipedia에서 제공하는 각 국가들의 지리적 인접국가 목록(https://en.wikipedia.org/wiki/List_of_political_and_geographic_borders)을 사용하였다. Table 2.는 Table 1.에서의 주요 국가들의 인접국 목록을 나타낸다. 앞서 언급했듯 중국과 북한이 국경을 공유하고 있다는 점에서 북한의 초미세먼지 농도에 중국의 영향이 있을 것으로 생각해 볼 수 있고, 한국의 경우 중국과 직접적으로 이웃하지는 않았지만 중국과 인접한 북한과 국경을 공유한다는 점에서 한국의 초미세먼지 농도가 중국, 북한의 초미세먼지 경향과 유사하게 나타나는 것은 자연스러워 보인다. 그에 반해 일본의 경우 인접 국가가 없다는 점에서 중국, 북한, 한국 등과 지리적 초미세먼지 농도 연관성이 크지 않을 것을 추론할 수 있다. 캐나다와 미국의 경우 역시 두 국가가 국경을 공유하고 있다는 점에서 유사한 초미세먼지 농도가 나타날 것이라고 판단하는 것은 자연스러워 보인다. 따라서 Table 2.의 자료를 크롤링(Web Crawling)하여 본 보고서에서 진행할 분석 모델들에 적용할 인접국가의 정보로서 모델에 반영하도록

국가	2010년	2011년	2012년	2013년	2014
한국	25.2	23.8	24.9	26.1	27.5
중국	58.2	57.2	57.4	56.9	58.0
북한	31.4	29.7	30.5	31.8	33.0
일본	12.4	11.8	12.0	12.4	12.9
미국	8.6	8.6	8.7	8.5	8.5
캐나다	7.3	7.4	7.3	7.3	7.2

Table 1: 주요 국가의 연평균 초미세먼지 농도




Figure 1: 2010년 초미세먼지 평균 농도




Figure 2: 2014년 초미세먼지 평균 농도

한다.

국가	인접국
한국	Democratic People's Republic of Korea
중국	Afghanistan / Bhutan / Hong Kong / India / Kazakhstan / Kyrgyzstan / Laos / Macau / Mongolia / Myanmar / Nepal / North Korea / Pakistan / Russia / Tajikistan / Vietnam
북한	China / Republic of Korea / Russia
일본	
미국	Canada / Mexico
캐나다	United States

Table 2: 주요 국가의 인접국가

또한 국가별 초미세먼지 농도에 영향을 주는 내부요인으로 국가별 에너지 사용량(kg of oil equivalent per capita), 전체 국가의 화석연료 사용 총량 대비 각국의 화석연료 사용량(% of total), 재생가능 에너지 소비량(% of total final energy consumption), 도시 인구(명), 각 국가의 숲 비율(%), 연간 평균 강수량(mm)의 자료를 사용하여 구체적인 내부요소에 따른 영향을 확인해 보도록 한다. 국가별 인구 특성을 반영할 수 있다는 점에서 국가별 에너지 사용량은 1인당 소비량을 데이터로 사용하며 재생 가능 에너지 소비량은 각 국가의 전체 에너지 사용량 중 재생 가능 에너지의 비율을 사용하도록 한다. 그에 반해 화석연료 사용량은 초미세먼지 농도에 직접적으로 영향을 줄 수 있다는 점에서 전 국가 중 해당 국가의 비율을 사용함으로써 각 국가별로 초미세먼지에 대한 영향력을 측정할 수 있도록 하였다. 또한 연평균 초미세먼지 농도에 대한 분석이라는 점에서 바람의 영향은 따로 고려하지 않도록 하며 강수량, 숲의 비율 등을 통해 초미세먼지를 억제하는 요소 역시 고려하도록 한다. 각 데이터의 결측치를 제외하고 총 108개국의 2010년부터 2014년까지의 자료를 사용하여 분석을 진행하도록 한다.

3 METHODS

공간 구조 특히 본 연구에서 사용하는 국가별 초미세먼지 농도와 같은 비정규적 격자 형태의 구조가 있는 데이터를 분석하기 위해서는 우선 공간 구조에 대한 정보를 반영하는 조건부 분포에 기반한 Gaussian Markov Random Fields(GMRF)를 이용할

수 있다. 데이터 $\mathbf{X} = (x_1, \dots, x_n)^T \in \mathbb{R}^n$ 가 labeled graph $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ 에 대해서 GMRF라는 것은 평균 μ , symmetric positive definite precision matrix $\mathbf{Q} = (Q_{ij})$ 에 대해서

$$f(\mathbf{x}) \propto |\mathbf{Q}|^{1/2} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^T \mathbf{Q}(\mathbf{x} - \mu)\right)$$

와 같은 형태를 가진다는 의미이다. 이 때 이웃한 공간 구조를 반영하기 위해 $Q_{ij} \neq 0$ iff $\{i, j\} \in \mathcal{E}$ for $i \neq j$ 와 같이 정의한다. 이 경우 $Q_{ij} = 0$ 은 i 와 j 인덱스의 데이터를 제외한 나머지 데이터들이 주어진 경우 x_i 와 x_j 사이에 조건부 독립임을 의미한다. 즉, $Q_{ij} = 0 \Leftrightarrow x_i \perp x_j | x_{-\{i,j\}}$ 와 같다. 조건부 분포의 구체적인 형태에 따라 Simultaneous Autoregressive model, Conditional Autoregressive model 등 다양한 형태의 모형이 정의된다. 3장에서는 이와 같은 비정규 격자 구조 형태의 데이터를 분석하는데 사용되는 모델을 소개하도록 한다.

3.1 MORAN'S I

우선, 구체적인 분석에 앞서 각 국가들의 초미세먼지 농도가 지리적 위치에 따른 연관성을 나타내는지 파악하기 위해 Moran's I 통계량을 확인해 본다. 공간적 구조를 반영하지 않는 두 확률 변수 $X = (X_1, \dots, X_n)$ 와 $Y = (Y_1, \dots, Y_n)$ 에 대해서 두 확률 변수 사이의 연관성은 일반적으로 Pearson's correlation coefficient를 통해 확인할 수 있다. 구체적으로 Pearson's correlation coefficient R 은 아래와 같이 표현된다.

$$R = \frac{\frac{1}{n} \sum_i (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\frac{1}{n} \sum_i (X_i - \bar{X})^2} \sqrt{\frac{1}{n} \sum_i (Y_i - \bar{Y})^2}}.$$

이 때 공간적 구조를 반영하는 확률변수 $\mathbf{Z} = (Z(s_1), \dots, Z(s_n)) = (Z_1, \dots, Z_n)$ 의 공간적 상관관계를 나타내는 통계량은 Moran's I 통계량으로 Pearson의 상관계수와 유사한 형태를 가지지만 공간적 의존성 정보를 반영하여 아래와 같이 표현된다.

$$I = \frac{n \sum_i \sum_j w_{ij} (Z_i - \bar{Z})(Z_j - \bar{Z})}{(\sum_i \sum_j w_{ij}) \sum_i (Z_i - \bar{Z})^2}$$

이러한 Moran's I는 1에 가까울 수록 강한 양의 공간적 상관관계를 가리키고 -1에 가까울 수록 강한 음의 공간적 상관관계를 의미한다. 또한 이 Moran's I 통계량에 permutation test를 적용하여 공간적 구조를 반영한 특성들의 임의성(randomization)을 검정할 수 있다.

3.2 SIMULTANEOUS AUTOREGRESSIVE MODEL

공간적 의존성은 공간적으로 가까운 거리의 데이터는 비슷한 성향을 나타낼 경향이 크다는 의미로 해석할 수 있는데, 만약 $\mathcal{N}_i$ 를 데이터 i 와 이웃한 데이터들의 집합이라고 할 때 i 위치에 있는 데이터는 이웃한 데이터들에 의해 영향을 받을 것이라는 점은 앞에서 언급했듯 초미세먼지의 농도를 분석하는데 있어 자연스러운 접근 방법이라 할 수 있다. 따라서 Z_i 를 i 위치에서의 특성값(여기서는 초미세먼지 농도)이라 할 때, Z_i 를 아래와 같은 관계식으로 표현할 수 있으며 이를 Simultaneous autoregressive model (SAR)이라고 한다.

$$Z_i = \mu_i + \sum_{j \in \mathcal{N}_i} \beta_{ij}(Z_j - \mu_j) + \epsilon_i, \epsilon_i \sim N(0, \sigma^2)$$

만약 $\mathbf{B} = (\beta_{ij})$ 라 정의하고 $i = j$ 이면 $\beta_{ij} = 0$, $j \in \mathcal{N}_i$ 인 경우에는 $\beta_{ij} > 0$ 라 하자. 또한 $\epsilon = (\epsilon_1, \dots, \epsilon_n)^T \sim N(\mathbf{0}, \Lambda)$ 그리고 $\mathbf{Z} = (Z_1, \dots, Z_n)^T$ 라 표현하면

$$\mathbf{Z} \sim N(\mu, (I_n - \mathbf{B})^{-1} \Lambda (I_n - \mathbf{B})^{-1T})$$

와 같이 표현된다. λ 를 공간적 자기상관 모수(spatial autocorrelation parameter)라고 하고 W 를 공간적 의존성(spatial dependence)을 반영하는 대칭행렬이라고 할 때 $\mathbf{B} = \lambda W$ 로 reparamterization을 할 수 있으며 이 경우

$$\mathbf{Z} \sim N(\mu, (I_n - \lambda W)^{-1} \Lambda (I_n - \lambda W)^{-1T})$$

와 같이 얻을 수 있다. 이 때 Λ 를 single parameter σ^2 으로 모수화할 때 분산에 해당하는 $Var(\mathbf{Z}) = \sigma^2(I_n - \lambda W)^{-1}(I_n - \lambda W)^{-1T}$ 는 최대우도(Maximum likelihood) 방법으로 효율적으로 추정이 가능해진다. ([Bivand, R. S. et al. , 2008])

3.3 CONDITIONAL AUTOREGRESSIVE MODEL

주변국들의 영향을 고려하는 또 다른 모형은 인접 국가들의 특성값들이 주어진 경우 즉 조건부 분포에 대한 가정을 통해 초미세먼지 농도를 고려하는 방법으로

$$Z_i | Z_j = z_j, j \neq i \sim N(\mu_i + \sum_{j \in \mathcal{N}_i} \beta_{ij}(x_j - \mu_j), \sigma^2)$$

와 같은 auto-normal model을 고려할 수 있다. 이 때, $\beta_{ii} = 0$ 인 경우

$$\begin{aligned}\mu_{i|-i} = E(Z_i|Z_{-i}) &= \mu_i + \sum_{j \neq i} \beta_{ij}(z_j - \mu_j) \\ Q_{i|-i} &= \frac{1}{\sigma_i^2} > 0\end{aligned}$$

와 같이 표현할 수 있고, Z_A 를 Z 의 공간 좌표 인덱스 중 A 라는 집합에 포함되는 경우에 대한 특성값 집합이라고 하고 $B = \mathcal{V} \setminus A$ 인 경우에 대해서

$$\begin{aligned}\mu_{A|B} &= \mu_A + Q_{AA}^{-1}A_{AB}(z_B - \mu_B) \\ Q_{A|B} &= Q_{AA}\end{aligned}$$

임을 과제에서 보였다. $A = \{i\}$ 인 single vertex인 경우에는

$$\begin{aligned}\mu_{i|-i} &= \mu_i - \sum_{j \in \mathcal{N}_i} \frac{Q_{ij}}{Q_{ii}}(z_j - \mu_j) \\ Q_{i|-i} &= Q_{ii}\end{aligned}$$

로 표현가능한데 이를 auto-normal model에 적용하면 $Q_{ii} = 1/\sigma_i^2$ 와 $-Q_{ij}/Q_{ii} = \beta_{ij}$ 로 나타낼 수 있고 이 때 precision matrix $\mathbf{Q}$ 로부터 $\beta_{ij}/\sigma_i^2 = \beta_{ji}/\sigma_j^2$ 로 표현가능하다. 또한 diagonally dominant인 경우에는 positive definite이 만족된다는 점으로부터

$$\mathbf{Z} \sim N(\mu, (I_n - B)^{-1}T)$$

로 표현가능하다. 이 때 $T = \text{diag}\{\sigma_1^2, \dots, \sigma_n^2\}$ 이며 $B = (\beta_{ij})$ 이다. 이러한 모형을 Conditional autoregressive model (CAR)이라고 한다.

이웃한 지역들에 대한 공간 정보를 반영한 proximity matrix $\mathbf{W}$ 를 고려하여 $\beta_{ij} = W_{ij}/W_{j+}$, $W_{i+} = \sum_{j \neq i} W_{ij}$ 그리고 $1/\sigma_i^2 = \tau^2 W_{i+}$, $\tau^2 > 0$ 으로 가정하면,

$$\begin{aligned}\mu_{i|-i} &= \mu_i + \sum_{j \neq i} \frac{W_{ij}}{W_{i+}}(z_j - \mu_j) \\ Q_{i|-i} &= \tau^2 W_{i+}\end{aligned}$$

로 표현가능하며 이 때의 precision matrix, $\mathbf{Q}$ 는

$$\mathbf{Q} = \tau^2(\mathbf{M} - \mathbf{W})$$

로 나타나는데 여기서 $\mathbf{M} = \text{diag}\{W_{1+}, \dots, W_{n+}\}$ 이다. $\mathbf{Q}\mathbf{1} = \tau^2(\mathbf{M} - \mathbf{W})\mathbf{1} = 0$ 로부터 $\mathbf{Q}$ 는 full rank가 아닌 행렬임을 알 수 있고 이를 intrinsic CAR 모형이라고 한다. 따라

서 이러한 intrinsic CAR 모형에 대안 형태로 proper CAR 모델들을 고려할 수 있는데 특별히 상관 모수 γ 를 사용하여 precision matrix $\mathbf{Q}$ 를 아래와 같이

$$\mathbf{Q} = \tau^2(\mathbf{M} - \gamma\mathbf{W})$$

나타낼 수 있다. 만약 γ 가 $\mathbf{Q}$ 를 positive definite을 만족하게하는 적당한 범위에 위치한다면 proper CAR 형태의 모형을 얻을 수 있다.

이 모형을 다차원 형태로 확장시킬 경우

$$\mathbf{Z} \sim N_{np}(\mu, ((\mathbf{M} - \gamma\mathbf{W}) \otimes \Lambda)^{-1})$$

로 표현가능한데 이 때 $\mathbf{Z} = (Z_1^T, \dots, Z_p^T)$ 이고 $Z_j = (Z_{1j}, \dots, Z_{nj})^T$ 이다. 이렇게 다차원 형태의 proper CAR를 이용하여 같은 공간좌표에서 동시에 여러 번 관측된 특성값들 또는 시간에 따라 같은 공간좌표에서 여러 번 관측된 특성값들 대한 상관관계를 고려한 모형을 설정할 수 있다.

3.4 CAR + AR(1)

[Rushworth, A. et al., 2014]는 공간 정보에 시간의 정보를 반영할 때 시간에 대한 자기상관 정보를 부여하는 모형을 제안하였다. 이 모형은 시공간적 자기상관 특성을 반영하는 모수가 부여되어 있으며 간단히

$$Z_j = \mathbf{x}_j^T \boldsymbol{\beta} + \phi_j + \epsilon_j$$

와 같이 표현가능하다. 여기서 ϕ_j 를 시간 j 에 대한 random effect를 나타내는 모수라고 가정하고 $Q(\gamma, W) = \mathbf{M} - \gamma\mathbf{W}$ 라 하면

$$\phi_j | \phi_{j-1} \sim N(\alpha \phi_{j-1}, \tau^2 Q(\gamma, W)^{-1}), j \in \{2, \dots, T\}$$

와 같이 ϕ_j 에 AR(1) 모형을 적용할 수 있으며 $\phi_1 \sim N(0, \tau^2 Q(\gamma, W)^{-1})$ 와 같이 초기값을 지정해 줄 수 있다. 즉 이 모형에서 시간에 대한 random effect ϕ_j 는 $j-1$ 시점의 영향을 받으며 precision matrix를 통해 공간적 정보 역시 포함하고 있음을 알 수 있다.

이 모형 역시 다차원으로 확장시켜 생각해 볼 수 있으며 구체적으로 만약 $T = 2$

라면, [Jin, X. , 2005]에 의하면 precision matrix 는 다음과 같이 표현가능하다.

$$Q(\gamma, W)^{-1} = ((\mathbf{M} - \gamma \mathbf{W}) \otimes \Lambda)^{-1} = \begin{bmatrix} (\mathbf{M}_1 - \gamma \mathbf{W}^{(1)})\Lambda_{11} & (\mathbf{M}_3 - \gamma \mathbf{W}^{(3)})\Lambda_{12} \\ (\mathbf{M}_3 - \gamma \mathbf{W}^{(3)})\Lambda_{21} & (\mathbf{M}_2 - \gamma \mathbf{W}^{(2)})\Lambda_{22} \end{bmatrix}^{-1}$$

이를 바탕으로 아래와 같이 시간에 대한 random effect 부분을 얻을 수 있다.

$$\begin{aligned} \phi_1 &\sim N(0, [\tau_2^2(\mathbf{M}_2 - \gamma \mathbf{W}^{(2)})]^{-1}) \\ \phi_2 | \phi_1 &\sim N(\alpha \phi_1, [\tau_1^2(\mathbf{M}_1 - \gamma \mathbf{W}^{(1)})]^{-1}) \end{aligned}$$

이 모형의 경우 일반적으로는 MCMC 및 Metropolis-Hastings algorithm 등 Bayesian approach를 통해 계산하여야 하나 모형의 복잡성과 모수추정에 있어 계산량을 고려하여 제 4장에서는 비교적 간단한 형태의 모형에 초미세먼지 데이터를 R package CARBayesST[Lee, D. et al. , 2016]를 이용하여 적합한 결과를 제시한다.

4 RESULTS

초미세먼지 데이터에 공간적 상관관계를 확인하기 위한 Moran's I 방법을 적용하여 임의성(randomization)에 대한 검정 결과는 아래 Table 3.과 같다. 2010년부터 매년 Moran's I 통계량이 커지고 있음을 알 수 있는데, 이는 2010년에 비해 최근에는 공간적인 상관관계가 커지고 있음을 의미한다. 점차 지리적 상관성이 커지고 있으며 따라서 초미세먼지의 영향에 대한 연구는 지역적 요인을 고려할 수 있는 SAR, CAR 등의 모형을 바탕으로 진행하는 것이 바람직한 연구임을 의미한다. 또한 permutation test를 이용한 임의성 검정(randomization test) 결과에 따르면 모든 연도에 대해서 임의적이지 않다는 결론을 얻을 수 있으며 이는 역시 지역적인 요인에 대해 고려해야한다는 결과를 뒷받침한다고 할 수 있다.

연도	Moran's I statistic	Moran I statistic standard deviate	p-value
2010년	0.610283873	7.8385	2.279e-15
2011년	0.600317140	7.7201	5.811e-15
2012년	0.620482516	7.9729	7.748e-16
2013년	0.627844507	8.0231	5.157e-16
2014년	0.640316179	8.145	< 2.2e-16

Table 3: Moran's I randomisation test

Table 4. - Table 8.은 각각 2010년부터 2014년까지의 국가별 초미세먼지 평균 농도에 대해서 지리적 인접 구조를 반영하여 국가별 에너지 사용량, 화석연료 사용량, 재생가능 에너지 사용량, 도시 인구, 숲의 비율 그리고 해당 연도의 평균 강수량의 정보를 바탕으로 SAR 모형을 적합한 결과이다. 각 연도별로 구체적인 모형의 적합값이 2010년 Lambda: 0.54579 LR test value: 31.144 p-value: 2.3961e-08, 2011년 Lambda: 0.53235 LR test value: 28.737 p-value: 8.2899e-08, 2012년 Lambda: 0.54946 LR test value: 31.002 p-value: 2.5775e-08, 2013년 Lambda: 0.58776 LR test value: 34.663 p-value: 3.9194e-09 마지막으로 2014년 Lambda: 0.60367 LR test value: 36.696 p-value: 1.3803e-09으로 얻어졌음을 통해 SAR 모형이 유의하게 적합되었음을 알 수 있다. 추정된 모수와 관련하여 우선 가장 눈의 띄는 점은 전체 에너지 사용량 중 재생가능한 에너지의 비율이 클 수록 초미세먼지 농도가 높게 나타난다는 점인데 이는 일반적인 관점과 다른 결과라 할 수 있다. 하지만 이는 재생가능한 에너지의 비율이 높은 상위 3개 국가가 국가가 콩고 민주 공화국, 나이지리아, 탄자니아와 같이 총 에너지 사용량이 낮은 국가들이란 점에서 일반적인 관점과 다른 결과가 나올 수 있음을 추측해 볼 수 있다. 또한 화석연료의 사용량이 클 수록 도시인구가 많을 수록 초미세먼지의 농도가 크게 나타남을 알 수 있는데 도시인구가 많을 수록 자동차 사용량이 증가할 것이라는 점에서 자동차 배기가스와 화석연료의 사용에 의한 분진 및 매연 등이 초미세먼지 농도에 영향을 준다는 것을 알 수 있다.

그에 반해 강수량과 숲의 비율이 클수록 초미세먼지의 농도가 낮게 나타남을 알 수 있는데 숲의 비율이 크고 강수량이 많은 국가일 수록 사막화가 덜 진행되었다는 점을 간접적으로 반영한다고 할 때, 그리고 강수량의 경우는 의도적인 노력과 무관한 점이라는 점에서 숲의 비율을 늘리는 노력을 통해 초미세먼지의 농도를 감소시킬 수 있다는 점을 함의한다고 할 수 있다. 또한 숲의 비율은 변수로 사용된 요인들 중 가장 낮은 유의확률을 나타내는 변수라는 점에서 특별히 의미있는 결과라 할 수 있다.

Table 9.부터 Table 13.은 CAR 모형을 적합한 결과이다. 추정된 모수의 크기와 부호는 SAR 모형의 결과들과 유사하므로 SAR과 유사한 해석이 가능하지만 전체적으로 변수들의 유의확률이 낮아졌음을 알 수 있다. 따라서 초미세먼지 농도에 대한 모형으로 SAR에 비해 CAR 모형이 더 적합하다고 생각할 수 있는데, 이는 특정 국가들의 초미세먼지 농도의 값들이 이웃한 국가에 직접적으로 영향을 줄 뿐 아니라 특정 국가의 초미세먼지에 영향을 주는 요소들 역시 고려하여 조건부 분포를 가정하였을 때 더 적절한 모형을 바탕으로 분석을 진행할 수 있음을 의미한다고 할 수 있다.

하지만 여전히 CAR 모형은 개별 연도에 대한 자료를 바탕으로 적합한 모형이므로 시간에 따라 독립적인 모형인데 CAR 모형에 AR(1) 모형을 적용하여 독립적으로

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	7.7341	15.9243	0.49	0.6272
energy	-3.3171	3.0546	-1.09	0.2775
fossil	0.2200	0.1565	1.41	0.1597
renewable	0.3546	0.1706	2.08	0.0376
urban	1.8809	1.2639	1.49	0.1367
rain	-3.4082	2.8093	-1.21	0.2251
forest	-0.1708	0.0946	-1.81	0.0711

Table 4: 2010년 SAR 결과

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	9.7081	16.5709	0.59	0.5580
energy	-3.0974	3.2562	-0.95	0.3415
fossil	0.2043	0.1621	1.26	0.2076
renewable	0.3527	0.1805	1.95	0.0507
urban	1.8106	1.2929	1.40	0.1614
rain	-1.7306	2.8065	-0.62	0.5375
forest	-0.1934	0.0963	-2.01	0.0445

Table 5: 2011년 SAR 결과

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	10.0218	16.2720	0.62	0.5380
energy	-2.4011	3.1580	-0.76	0.4471
fossil	0.2020	0.1598	1.26	0.2063
renewable	0.3202	0.1759	1.82	0.0687
urban	1.5903	1.2527	1.27	0.2043
rain	-1.7141	2.8118	-0.61	0.5421
forest	-0.1591	0.0961	-1.66	0.0978

Table 6: 2012년 SAR 결과

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	13.2599	14.7192	0.90	0.3677
energy	-3.5377	2.9802	-1.19	0.2352
fossil	0.1831	0.1434	1.28	0.2019
renewable	0.2481	0.1578	1.57	0.1159
urban	1.3109	1.1488	1.14	0.2538
rain	0.0904	2.6628	0.03	0.9729
forest	-0.1538	0.0905	-1.70	0.0895

Table 7: 2013년 SAR 결과

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	10.7369	13.6777	0.78	0.4325
energy	-2.2730	2.8690	-0.79	0.4282
fossil	0.1890	0.1331	1.42	0.1556
renewable	0.2827	0.1495	1.89	0.0586
urban	1.3136	1.0802	1.22	0.2240
rain	-2.2976	2.7127	-0.85	0.3970
forest	-0.1106	0.0879	-1.26	0.2087

Table 8: 2014년 SAR 결과

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.6770	18.4142	-0.09	0.9274
energy	-3.4560	3.0829	-1.12	0.2623
fossil	0.3281	0.1842	1.78	0.0749
renewable	0.4470	0.1951	2.29	0.0220
urban	6.9379	1.6696	4.16	0.0000
rain	-4.7014	2.5348	-1.85	0.0636
forest	-0.1972	0.1055	-1.87	0.0615

Table 9: 2010년 CAR 결과

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.6494	18.9411	-0.03	0.9727
energy	-3.4390	3.2543	-1.06	0.2906
fossil	0.3207	0.1887	1.70	0.0892
renewable	0.4598	0.2034	2.26	0.0238
urban	6.7916	1.6773	4.05	0.0001
rain	-3.3991	2.5313	-1.34	0.1793
forest	-0.2163	0.1050	-2.06	0.0394

Table 10: 2011년 CAR 결과

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-2.1983	18.7356	-0.12	0.9066
energy	-2.6214	3.1524	-0.83	0.4057
fossil	0.3345	0.1874	1.78	0.0743
renewable	0.4611	0.2004	2.30	0.0214
urban	6.8668	1.6602	4.14	0.0000
rain	-3.2285	2.5577	-1.26	0.2068
forest	-0.1929	0.1059	-1.82	0.0685

Table 11: 2012년 CAR 결과

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.0761	17.3313	-0.06	0.9505
energy	-3.3229	3.0101	-1.10	0.2696
fossil	0.3388	0.1731	1.96	0.0503
renewable	0.4215	0.1843	2.29	0.0222
urban	6.5936	1.5957	4.13	0.0000
rain	-1.7474	2.4013	-0.73	0.4668
forest	-0.1968	0.1020	-1.93	0.0536

Table 12: 2013년 CAR 결과

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-4.1913	16.2601	-0.26	0.7966
energy	-3.0999	2.9091	-1.07	0.2866
fossil	0.3538	0.1625	2.18	0.0295
renewable	0.4451	0.1744	2.55	0.0107
urban	6.4360	1.5348	4.19	0.0000
rain	-3.8434	2.3862	-1.61	0.1072
forest	-0.1489	0.1008	-1.48	0.1397

Table 13: 2014년 CAR 결과

고려한 시간에 대한 영향력을 고려할 경우 더 합리적인 결과를 얻을 수 있을 것으로 기대되며 이를 반영한 CAR+AR(1) 모형은 R package CARBayesST의 "ST.CARar" 함수를 사용하여 적합할 수 있다. 구체적인 함수 옵션으로 number of samples는 1,000,000, burn-in 10,000, thin 100으로 설정하였다. 적합 결과는 아래 Table 14. 와 같이 얻어졌는데 에너지 사용량을 제외하고 모든 변수들의 95%신뢰구간(여기서는 95% credible set)이 0을 포함하지 않는다는 점에서 각 변수들의 유의한 영향을 미치고 있음을 알 수 있는데 특히 도시인구와 강수량이 큰 영향을 미치는 것으로 나타났다. 즉 자동차 사용량과 관계되었을 것으로 추정되는 도시인구의 영향과 연간 평균 강수량이 초미세먼지 농도에 영향을 크게 미치며 또한 숲의 비율 역시 초미세먼지에 영향을 미치는 것을 알 수 있다. 또한 Figure 3. 과 Figure 4.에서 나타나는 모수들의 trace plot을 보면 대부분 수렴을 했다고 가정할 수 있을 것으로 판단된다.

	Median	2.5%	97.5%	n.sample	% accept	n.effective	Geweke.diag
(Intercept)	10.97	-2.47	23.30	9900.00	100.00	52.80	1.50
ϕ	61.53	-54.22	176.28	9900.00	100.00	253.60	-1.60
energy	-0.00	-0.03	0.02	9900.00	100.00	140.70	2.20
fossil	0.20	0.07	0.34	9900.00	100.00	50.80	-0.90
renewable	0.38	0.23	0.54	9900.00	100.00	39.00	-1.70
urban	2.42	1.38	3.45	9900.00	100.00	85.10	0.20
rain	-2.13	-3.91	0.00	9900.00	100.00	36.70	1.70
forest	-0.24	-0.33	-0.15	9900.00	100.00	34.10	-0.80
tau2	113.29	98.50	130.95	9900.00	100.00	1915.00	-1.00
nu2	0.01	0.00	0.14	9900.00	100.00	1546.90	1.30
rho.S	0.54	0.41	0.66	9900.00	43.80	375.80	0.30
rho.T	0.95	0.91	0.99	9900.00	100.00	9473.00	0.50

Table 14: CAR AR(1) 결과

5 CONCLUSION

초미세먼지의 구성 성분 그리고 그로 인한 초미세먼지의 구체적인 발생 원인에 대한 연구에는 국가별 지리적 요소를 고려해야 하는 것이 자연스럽다. 실제로 초미세먼지 주요 발생국의 주변 국가들 역시 높은 초미세먼지 농도를 나타내는 경향이 짙은데




Figure 3: CAR AR(1) trace plot 1




Figure 4: CAR AR(1) trace plot 2

이러한 지리적 요소를 반영하여 초미세먼지에 영향을 주는 요인을 밝혀내기 위해 본 보고서에서는 지리적 인접국가들의 정보를 바탕으로 Simultaneous Autoregressive Model, Conditional Autoregressive Model을 고려하였고 또한 시간에 따른 영향을 파악하기 위해 시간의 효과를 random effect로 고려하는 CAR+AR(1) 모형을 고려하였다. 세 모형 모두 변수들의 부호는 모두 같았는데 이는 각 변수들이 초미세먼지에 미치는 영향의 방향은 모형과 상관없이 일치한다는 것을 의미하지만 모형에 따라 구체적인 적합정도에 차이가 있음을 나타내었다. 본 보고서에 얻은 결과에 따르면 강수량과 같은 자연적인 현상 외에 숲의 비율을 늘린다든지 도시 인구의 감소 즉 도시 인구에 의한 차량 이용률 등을 감소시키는 것과 같은 인위적인 노력에 의해서 초미세먼지 농도가 감소할 수 있으며 이러한 요소와 관련되는 정책적 제안이 필요할 수 있다고 판단할 수 있다.

물론 전세계적으로 같은 형태로 수집된 데이터를 얻는 것이 쉽지 않기 때문에 분석에 더 적합한 데이터를 사용하지 못했다는 점, 국가들 사이의 거리에 따른 이웃 국가 목록 구축 및 국가 별, 지역 별로 세분화된 데이터의 획득이 어려운 점 등의 요인 등으로 신뢰성있는 결과라고 단정할 수는 없지만 초미세먼지에 대한 연구에 지리적 요소를 고려한 연구라는 점에서 본 보고서에서 사용되는 접근방법과 시간-공간적 모형들이 향후 초미세먼지 연구에 의미 있는 결과를 도출하는데 있어 통계학적 의미를 가질 것으로 기대한다.

REFERENCES

- Bivand, R. S., Pebesma, E. J., and Gomez-Rubio, V. (2008). Applied spatial data analysis with R *Springer*
- Jin, X., Carlin, B. P., and Banerjee, S. (2005). Generalized Hierarchical Multivariate CAR Models for Areal Data *Biometrics*
- Lee, D., Rushworth, A., and Napier, G. (2016). Spatio-Temporal Areal Unit Modeling in R with Conditional Autoregressive Priors Using the CARBayesST Package. *R*, <https://cran.r-project.org/web/packages/CARBayesST/vignettes/CARBayesST.pdf>
- Rushworth, A., Lee, D., and Mitchell, R. (2014). A spatio-temporal model for estimating the long-term effects of air pollution on respiratory hospital admissions in Greater London. *Spatial and Spatio-temporal Epidemiology*, 10, 29-38.
- 조재근 기자 (2017. 06. 09). 미세먼지 갈수록 심각... 청정한 하늘 매년 줄어든다. *충청일보*, <http://www.cctoday.co.kr/?mod=news&act=articleView&idxno=1066018>